


## Линейная регрессия



Оценивание обобщ. способности:

1) отлост. выборка

2) кросс-валидация



$X^k$  -  $k$ -й дел

$X^{1k}$  - все деления, кроме  $k$ -го

$$CV = \frac{1}{K} \sum_{k=1}^K Q(\alpha(x; X^{1k}), X^k)$$

↗ обдрана на  $X^{1k}$

Leave-one-out  
 $K=1$

Итоговая модель: 1) обдуть на всех данных

2) усреднить  $K$  моделей

$$c(x) = \frac{1}{K} \sum_{k=1}^K \alpha(x, X^{1k})$$

## Борда с переобучением

В ①  $w_j$  очень большие  
 $10^6, 10^7, \dots$

Регуляризация - запрет на слишком веса

$Q(w, X)$  - как функционал

$$\underbrace{Q(w, X) + \underbrace{\lambda \|w\|_2^2}_{\substack{\text{коэф. регуляризатор} \\ \text{регуляризу.}}}}_{\substack{\text{коэф. регуляризатор} \\ \text{регуляризу.}}} \rightarrow \min_w \quad \left\{ \begin{aligned} w &= (X'X + \lambda I)^{-1} X'y \\ &\text{(для MSE)} \end{aligned} \right. \quad \boxed{\lambda \geq 0}$$

Важно: в  $\|w\|_2^2$  не входит  $w_0$  !!!  
(иначе  $Q(x)$  не сможет быть  
одного порядка с  $y$ )

Почему больше веса - плохо?

$$Q(x) = 10^6 + \underbrace{3 \cdot 10^7 \text{ (площадь)}}_{\substack{\text{площадь} = 0.001 \\ Q(x) = \frac{3 \cdot 10^4}{30.000}}} - 5 \cdot 10^6 \cdot \text{(рост. до метр.)}$$

Как выбирать  $\lambda$ ?

- по общ. выбору: выбираем  $\lambda$ ,  
при которой  $Q(\lambda, X)$  минимальна  
плохо - оптимально  $\lambda = 0$

Гиперпараметр - нельзя подбирать по общ. выд.  
вводится для лучшей качества  
на новых данных

нужно подбирать по CV или отложен. выд.



Регуляризу. не обязательно через  $L_2$ -норму!

$$Q(w, X) + \lambda \|w\|_1 \rightarrow \min \quad \lambda \geq 0$$

$$= \sum_{j=1}^n |w_j| \quad \boxed{\|w\|_1}$$

Почему стили. в  $X$  есть лин. зав. колонки.

... ..

$$\exists v \forall x \in X \quad \langle v, x \rangle = 0$$

$w_*$  - миним по MSE веса

$$\langle \underbrace{w_* + \alpha v}_\rightarrow, x \rangle = \langle w_*, x \rangle + \alpha \underbrace{\langle v, x \rangle}_{=0} = \langle \underbrace{w_*}_\rightarrow, x \rangle$$


т.е. решение много

$$w_* + \alpha v \xrightarrow{\alpha \rightarrow \infty}$$

Обучение лин. регр.

$$\text{для MSE: } w = \underbrace{(X^T X)^{-1}}_{Q(d^3)} X^T y$$

Градиентное обучение моделей



1)  $w^{(0)}$  - начальное приближение

$\nabla_w Q(w)$  - градиент  $Q$  по  $w$

$-\nabla Q(w)$  - в сторону наи скорейш. убывания

2)  $w^{(k)} = w^{(k-1)} - \underbrace{\eta_k}_{\substack{\text{длина шага} \\ \text{(learning rate)}}} \nabla Q(w^{(k-1)})$  - шаг град. спуска

3) когда останавливаться?

- когда ошибка на тесте перестает уменьшаться

$$- \|w^{(k)} - w^{(k-1)}\| < \epsilon$$

$$- |Q(w^{(k)}, X) - Q(w^{(k-1)}, X)| < \epsilon$$

Сходимость: 1) к  $\nabla Q(w) \approx 0$

для лин. моделей с матрицей  
полного ранга такая точка  
одна

2) если решений не скалько,  
то можно делать мульти-  
стар



Улучшения GD

оценки  
градиента

градиентный  
метод


Оценивание градиента

$$Q(w, X) = \frac{1}{2} \sum_{i=1}^l (\langle w, x_i \rangle - y_i)^2$$

$$Q(w, X) = \frac{1}{2} \sum_{i=1}^l q_i(w)$$

$$\nabla_w Q(w, X) = \frac{1}{2} \sum_{i=1}^l \nabla_w q_i(w)$$

полный  
градиент



Стохастический GD (SGD):  $\nabla Q(w) \approx \nabla q_{i_k}(w)$

$$w^{(k)} = w^{(k-1)} - \eta_k \nabla q_{i_k}(w^{(k-1)})$$

$$q_{i_k} = (\langle w, x_{i_k} \rangle - y_{i_k})^2$$

$i_k$  - случай. номер обзекта



$$\rightarrow \sum_{k=1}^{\infty} \eta_k = \infty$$

$$\rightarrow \sum_{k=1}^{\infty} \eta_k^2 = \text{const}$$

$$\frac{1}{k} = \frac{1}{k}$$

$$\frac{1}{k} = \alpha \left( \frac{s_0}{s_0 + k} \right)^p$$

$\alpha, s_0, p$  - параметры

Full GD:

$$Q(w^{(k)}) - Q(w_*) =$$

$$= O\left(\frac{1}{k}\right)$$

$$\text{SGD: } = O\left(\frac{1}{\sqrt{k}}\right)$$

Mini-batch GD:

$$\nabla Q(w) \approx \frac{1}{n} \sum_{j=1}^n \nabla q_{i_k j}(w)$$

$$\text{SAG: } z_i^{(0)} = \nabla q_i(w^{(0)})$$

$$k\text{-я итерация: } z_i^{(k)} = \begin{cases} \nabla q_i(w^{(k-1)}), & i = i_k \\ z_i^{(k-1)}, & \text{иначе} \end{cases}$$

$$\nabla Q(w^{(k-1)}) \approx \frac{1}{l} \sum_{i=1}^l z_i^{(k)}$$

$$O\left(\frac{1}{k}\right)$$